

НИУ ВШЭ
Прикладная математика

Отчет по проекту

Сравнение методов тематической классификации текстов

Выполнила: Ильина Любовь

Группа: БПМ255

Преподаватель: Константинова Елизавета

Москва, 2026

Содержание

Аннотация	2
1 Введение	3
1.1 Цель работы	3
1.2 Задачи работы	3
2 Описание данных	3
2.1 AG News	4
2.2 DBpedia	4
2.3 RuNews	4
3 Предобработка текста	4
4 Методы	5
4.1 Bag of Words	5
4.2 TF-IDF	6
4.3 Word2Vec Skip-gram	7
4.4 Word2Vec CBOW	8
4.5 fastText	9
5 Ограничения методов	10
6 Эксперименты	11
7 Результаты	11
8 Обсуждение	12

Аннотация

В работе рассматривается задача тематической классификации текстов.

Цель проекта заключается в сравнении нескольких методов представления текстовых данных и их применении к задаче многоклассовой классификации.

В качестве данных используются три датасета: AG News, DBpedia и RuNews.

Для построения признакового описания текстов рассматриваются Bag of Words, TF-IDF, Word2Vec Skip-gram, Word2Vec CBOW и fastText.

Качество моделей оценивается на тестовых выборках с помощью accuracy.

1. Введение

Задача классификации текстов является одной из базовых задач обработки естественного языка. Она применяется в автоматической рубрикации новостей, фильтрации спама, анализе отзывов, определении тематики документов и других прикладных задачах.

В последние годы в NLP активно развиваются нейросетевые методы, включая трансформерные архитектуры и большие языковые модели. Однако классические подходы к представлению текста, такие как Bag of Words, TF-IDF, fastText и Word2Vec, по-прежнему остаются важными базовыми методами. Они проще в реализации, быстрее обучаются и позволяют получить интерпретируемые признаки. Поэтому сравнение таких методов является полезным этапом при изучении задачи классификации текстов.

В данной работе рассматривается тематическая классификация текстов. Основной акцент сделан не на построении самой сложной модели, а на сравнении разных способов векторизации текста и анализе их качества на нескольких датасетах.

1.1. Цель работы

Целью работы является сравнение методов представления текстов для задачи тематической классификации.

1.2. Задачи работы

Для достижения цели были поставлены следующие задачи:

- подготовить несколько датасетов для классификации текстов;
- выполнить единую предобработку текстов;
- реализовать несколько способов векторизации текстов;
- обучить классификаторы на полученных признаках;
- сравнить качество моделей на тестовых выборках;
- проанализировать преимущества и ограничения рассмотренных методов.

2. Описание данных

В работе использовались три датасета: AG News, DBpedia и RuNews. Два из них содержат новостные тексты, а DBpedia состоит из энциклопедических аннотаций объектов из Википедии. Это позволяет проверить методы как на новостных данных, так и на текстах другого типа.

Датасет	Язык	Кол-во классов	Train	Test	Тип текстов
AG News	английский	4	120000	7600	новости
DBpedia	английский	14	560000	70000	энциклопедические описания
RuNews	русский	11	57530	14383	новости

Таблица 1: Используемые датасеты

2.1. AG News

AG News содержит англоязычные новости, разделенные на четыре тематические категории: мир, спорт, бизнес, наука и технологии. Этот датасет используется как основной набор данных для первичного сравнения методов.

2.2. DBpedia

DBpedia содержит текстовые описания объектов из Википедии. В отличие от AG News, этот датасет не является новостным, поэтому он используется для проверки того, насколько хорошо методы работают на другом типе текстов.

2.3. RuNews

RuNews содержит русскоязычные новости, размеченные по тематическим категориям. Он используется для проверки качества методов на русском языке.

3. Предобработка текста

Предобработка текстов выполнялась одинаково для всех датасетов и включала следующие шаги:

- приведение текста к нижнему регистру;
- удаление HTML-артефактов;
- удаление знаков пунктуации и специальных символов;
- сохранение только русских и английских букв, цифр и пробелов;
- удаление лишних пробелов.

Для моделей Word2Vec Skip-gram, Word2Vec CBOW и fastText дополнительно применялась специальная подготовка обучающей последовательности. Из словаря удалялись слишком редкие слова, встретившиеся не более 5 раз, а для слишком частотных слов использовалась субдискретизация. Эти дополнительные шаги нужны именно для методов, обучающих эмбединги, поскольку они строят векторные представления слов на основе контекстов.

Часто встречающиеся слова, например *the, of, for*, обычно не дают полезного контекста для соседних слов. Их большое количество может создавать шум и замедлять обучение. Поэтому для каждого слова w_i в обучающем наборе задавалась вероятность удаления:

$$P(w_i) = 1 - \sqrt{\frac{t}{f(w_i)}},$$

где t — пороговый параметр, а $f(w_i)$ — относительная частота слова w_i в корпусе.

Чем чаще слово встречается в корпусе, тем выше вероятность его удаления. За счёт этого уменьшается влияние слишком частотных слов, обучение становится быстрее, а полученные эмбединги лучше отражают содержательные контексты.

При этом для Bag of Words и TF-IDF такая случайная субдискретизация не применялась, так как эти методы напрямую используют частоты слов в документах. Для них удаление части частотных слов могло бы исказить исходные частотные признаки.

4. Методы

В работе были рассмотрены пять методов представления текстов:

- Bag of Words;
- TF-IDF;
- Word2Vec Skip-gram;
- Word2Vec CBOW;
- fastText.

4.1. Bag of Words

Bag of Words является одним из самых простых способов представления текста. В этом подходе каждый текст описывается вектором частот слов. Порядок слов при этом не учитывается, а учитывается только то, какие слова встретились в тексте и сколько раз.

Преимущество этого метода состоит в простоте и высокой интерпретируемости. Однако он плохо учитывает смысл слов и полностью теряет информацию о порядке слов в предложении.

Пусть словарь состоит из следующих слов:

$$V = (\text{market}, \text{stock}, \text{team}, \text{game}, \text{win})$$

Рассмотрим текст:

“stock market market”

Тогда представление этого текста в модели Bag of Words будет иметь вид:

$$x = (2, 1, 0, 0, 0)$$

Такой вектор означает, что слово *market* встретилось в тексте 2 раза, слово *stock* — 1 раз, а слова *team*, *game* и *win* не встретились ни разу.

Схематично это можно представить следующим образом:

$$\text{“stock market market”} \longrightarrow (\text{market, stock, team, game, win}) \longrightarrow (2, 1, 0, 0, 0)$$

Для большей наглядности это же представление можно записать в виде таблицы:

market	stock	team	game	win
2	1	0	0	0

Таким образом, каждому тексту сопоставляется числовой вектор фиксированной длины, равной размеру словаря. Компоненты этого вектора показывают, сколько раз соответствующее слово встретилось в документе.

4.2. TF-IDF

TF-IDF — это статистический метод представления текста, который позволяет оценить важность слова в документе с учетом всей коллекции документов. Название метода состоит из двух частей: TF и IDF.

TF (Term Frequency, частота термина) показывает, насколько часто определенное слово встречается в данном документе. Иными словами, TF измеряет важность слова внутри конкретного текста: чем чаще слово встречается в документе, тем больше его вклад.

IDF (Inverse Document Frequency, обратная частота документа) показывает, насколько уникальным является слово во всей коллекции документов. Если слово встречается почти во всех документах, то его IDF будет низким, так как такое слово не несет большой информационной ценности для различения текстов. Наоборот, слова, которые встречаются редко, получают больший вес.

Формула TF-IDF объединяет эти две идеи и вычисляет вес термина t в документе d :

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \cdot \text{IDF}(t),$$

где:

- $\text{TF}(t, d)$ — частота термина t в документе d ;
- $\text{IDF}(t)$ — обратная частота документа для термина t .

Таким образом, TF-IDF присваивает наибольший вес словам, которые часто встречаются в одном документе, но редко встречаются в остальных документах коллекции. Именно поэтому этот метод хорошо подходит для тематической классификации текстов: характерные слова темы помогают отличать документы одного класса от документов других классов.

Классические подходы к взвешиванию терминов в информационном поиске подробно рассматривались в работе Salton и Buckley [1].

4.3. Word2Vec Skip-gram

Word2Vec Skip-gram является нейросетевым методом получения векторных представлений слов. Идея метода состоит в том, чтобы по центральному слову предсказывать слова из его контекста. В результате обучения каждому слову сопоставляется плотный вектор фиксированной размерности. Слова, которые встречаются в похожих контекстах, получают близкие векторные представления.

Метод Skip-gram был предложен в работе Mikolov и соавторов [2]. В отличие от Bag of Words и TF-IDF, Word2Vec позволяет учитывать не только факт появления слова в тексте, но и его смысловую близость к другим словам.

Для обучения Skip-gram текст сначала преобразуется в последовательность слов. Затем для каждого слова выбирается окно контекста фиксированного размера. Центральное слово используется как вход модели, а слова вокруг него становятся целевыми значениями.

Например, пусть есть фрагмент текста:

the company reported strong quarterly earnings

Если размер окна равен 2, то для центрального слова *reported* контекстом будут слова:

company, strong

Тогда для Skip-gram формируются обучающие пары:

(reported, company), (reported, strong)

То есть модель учится по слову *reported* предсказывать слова, которые находятся рядом с ним.

Схематично это можно представить так:

reported $\longrightarrow$ {company, strong}

При обучении такие пары объединяются в батчи. Батч представляет собой набор пар вида “центральное слово — слово из контекста”. Например:

$$X = \begin{bmatrix} \text{reported} \\ \text{reported} \\ \text{strong} \\ \text{strong} \end{bmatrix}, \quad y = \begin{bmatrix} \text{company} \\ \text{strong} \\ \text{reported} \\ \text{quarterly} \end{bmatrix}$$

После этого слова заменяются на их числовые индексы из словаря. На вход нейросети подаются индексы центральных слов, а целевыми значениями являются индексы слов из контекста. В процессе обучения обновляются веса слоя эмбедингов. Именно эти веса после обучения и являются векторными представлениями слов.

4.4. Word2Vec CBOW

CBOW является второй архитектурой Word2Vec. В отличие от Skip-gram, CBOW решает обратную задачу: по словам из контекста предсказывает центральное слово. Обычно CBOW обучается быстрее, но может хуже работать с редкими словами, так как усредняет информацию из контекста.

Например, для того же фрагмента текста:

the company reported strong quarterly earnings

и окна размера 2 для центрального слова *reported* контекстом являются слова:

company, strong

Но теперь входом модели является не центральное слово, а его окружение:

$$\{\text{company, strong}\} \longrightarrow \text{reported}$$

То есть модель учится по соседним словам восстанавливать центральное слово.

Для CBOW обучающие примеры имеют вид:

$$X = \begin{bmatrix} \{\text{company, strong}\} \\ \{\text{reported, quarterly}\} \\ \{\text{quarterly, earnings}\} \end{bmatrix}, \quad y = \begin{bmatrix} \text{reported} \\ \text{strong} \\ \text{strong} \end{bmatrix}$$

После преобразования слов в числовые индексы каждый объект в батче содержит несколько слов контекста. Эмбединги этих слов извлекаются из embedding-слоя и обычно усредняются. Полученный средний вектор используется для предсказания центрального слова.

Схематично CBOW можно представить так:

$$\{\text{company, strong}\} \longrightarrow \text{reported}$$

Таким образом, различие между Skip-gram и CBOW состоит в направлении пред-

сказания:

Skip-gram: центральное слово $\longrightarrow$ контекст

CBOW: контекст $\longrightarrow$ центральное слово

В обоих случаях после обучения основной результат модели — это не сам классификатор, а матрица эмбедингов. Каждому слову из словаря соответствует вектор, который хранит информацию о том, в каких контекстах это слово встречалось.

Для решения задачи классификации текстов полученные эмбединги использовались как признаки. Каждый текст представлялся одним вектором: для всех слов текста брались их эмбединги, после чего эти векторы усреднялись. Таким образом, текст переводился в вектор фиксированной размерности:

$$v_{\text{text}} = \frac{1}{n} \sum_{i=1}^n v_{w_i},$$

где v_{w_i} — эмбединг i -го слова текста, а n — количество слов в тексте.

После этого полученные векторы документов подавались в логистическую регрессию, которая уже решала задачу классификации.

Как и Skip-gram, CBOW был предложен в работе Mikolov и соавторов [2].

4.5. fastText

fastText является развитием идей Word2Vec и используется для получения векторных представлений слов и классификации текстов. Главное отличие fastText состоит в том, что слово представляется не только как отдельная единица, но и через набор символьных n -грамм. Это позволяет модели учитывать внутреннюю структуру слова.

Метод fastText был предложен Bojanowski и соавторами для обучения векторных представлений слов с использованием подслов [3].

Также fastText применяется для эффективной классификации текстов [4].

Одно из преимуществ метода заключается в высокой скорости обучения и хорошей точности на задачах классификации текстов.

Например, рассмотрим слово:

company

Для него можно выделить символьные n -граммы, например длины 3:

com, omp, mpa, ran, any

Схематично это можно представить так:

$$\text{company} \longrightarrow \{\text{com}, \text{omp}, \text{mpa}, \text{pan}, \text{any}\}$$

Тогда вектор слова строится не только по самому слову, но и по векторам его символьных частей:

$$v_{\text{company}} = v_{\text{word}} + v_{\text{com}} + v_{\text{omp}} + v_{\text{mpa}} + v_{\text{pan}} + v_{\text{any}}.$$

Благодаря этому модель может строить более информативные представления для редких слов, а также лучше работать со словами, которые имеют похожую структуру. Например, слова с общими корнями или похожими окончаниями могут получать близкие векторные представления.

В данной работе fastText использовался не как самостоятельный классификатор, а как способ получить эмбединги слов. После обучения модели каждому слову сопоставлялся вектор фиксированной размерности. Затем каждый текст представлялся одним вектором: для всех слов текста брались их эмбединги, после чего они усреднялись:

$$v_{\text{text}} = \frac{1}{n} \sum_{i=1}^n v_{w_i},$$

где v_{w_i} — fastText-вектор i -го слова текста, а n — количество слов в тексте.

После этого полученные векторы документов подавались в логистическую регрессию, которая выполняла итоговую классификацию.

5. Ограничения методов

Каждый из рассмотренных методов имеет свои ограничения.

Bag of Words прост в реализации, но не учитывает порядок слов и смысловую близость между словами. Например, слова с похожим значением будут считаться полностью разными признаками.

TF-IDF также не учитывает порядок слов и контекст, однако лучше выделяет важные для документа слова. Этот метод может хорошо работать на тематической классификации, но хуже справляется с задачами, где важен смысл фразы целиком.

Word2Vec Skip-gram и CBOW позволяют получать плотные векторные представления слов, но требуют большего времени на обучение. Кроме того, качество этих методов зависит от размера корпуса и параметров обучения.

fastText учитывает символьные n -граммы и поэтому лучше работает с редкими словами и разными формами слов. Однако он также требует подбора параметров и может быть менее интерпретируемым, чем TF-IDF.

6. Эксперименты

Для каждого датасета модели обучались на обучающей выборке и оценивались на тестовой выборке.

Базовая очистка текста была одинаковой для всех методов. Различия в дополнительной обработке были связаны с особенностями самих алгоритмов: для Word2Vec и fastText применялись удаление редких слов и субдискретизация частотных слов, так как эти шаги используются при обучении эмбеддингов.

Для всех методов в качестве итогового классификатора использовалась логистическая регрессия.

Для Bag of Words и TF-IDF признаки строились на уровне документов. Для Word2Vec Skip-gram, Word2Vec CBOW и fastText сначала обучались векторные представления слов, после чего вектор документа получался усреднением эмбеддингов всех слов текста.

Параметр	Значение
Классификатор	логистическая регрессия
Размерность эмбеддингов	128
Число эпох Word2Vec/fastText	5
Основная метрика	ассурасу

Таблица 2: Основные параметры экспериментов

Для оценки качества использовалась метрика ассурасу. Дополнительно для анализа качества по отдельным классам использовались precision, recall и F1-score.

Реализация всех методов, код предобработки данных, обучения моделей и вычисления метрик: GitHub.

7. Результаты

В таблице приведены результаты классификации для разных методов и датасетов. Для каждого метода указано значение ассурасу на тестовой выборке.

Метод	AG News	DBpedia	RuNews
TF-IDF	0.92	0.98	0.86
Bag of Words	0.91	0.98	0.85
Word2Vec Skip-gram	0.88	0.94	0.81
fastText	0.87	0.94	0.80
Word2Vec CBOW	0.86	0.94	0.79

Таблица 3: Сравнение ассурасу для разных методов

На AG News и RuNews наилучшее качество показал TF-IDF. На DBpedia TF-IDF и Bag of Words дали одинаковый результат, равный 0.98. В целом частотные методы оказались сильнее методов на основе усредненных эмбедингов.

Среди методов на основе эмбедингов наилучший результат показал Word2Vec Skip-gram. fastText и Word2Vec CBOW дали близкие значения, однако уступили как TF-IDF, так и Bag of Words на всех трех датасетах.

8. Обсуждение

Полученные результаты показывают, что для задачи тематической классификации текстов частотные признаки являются очень сильным baseline-подходом. TF-IDF оказался наиболее устойчивым методом: он показал лучшее качество на AG News и RuNews и совпал с Bag of Words на DBpedia. Это связано с тем, что в тематической классификации большую роль играют отдельные ключевые слова, характерные для конкретного класса.

Bag of Words также показал высокое качество. На DBpedia его результат совпал с TF-IDF, что можно объяснить особенностями этого датасета: энциклопедические описания объектов часто содержат явные тематические слова, по которым классы хорошо различаются даже без дополнительного взвешивания через IDF.

Методы Word2Vec Skip-gram, Word2Vec CBOW и fastText показали более низкие результаты. Основное ограничение в данной работе связано не с самими эмбедингами, а со способом построения вектора документа. Каждый текст представлялся как среднее значение векторов его слов, поэтому часть информации о наиболее важных тематических словах терялась.

Среди методов на основе эмбедингов Skip-gram оказался немного сильнее CBOW. Это можно объяснить тем, что Skip-gram обычно лучше обучает представления редких и информативных слов, тогда как CBOW сильнее усредняет информацию из контекста.

fastText теоретически имеет преимущество за счет использования символьных n-грамм, особенно для редких слов и языков с богатой морфологией. Однако в проведенных экспериментах это преимущество проявилось не полностью. Вероятно, это связано с усреднением векторов слов и предварительным удалением редких слов.

Отдельно можно отметить, что на DBpedia все методы показали достаточно высокие результаты. На RuNews качество оказалось ниже, чем на английских датасетах, что может быть связано с особенностями русского языка и большим числом словоформ.

Таким образом, по результатам экспериментов наиболее удачным методом среди рассмотренных оказался TF-IDF. Он сочетает простоту реализации, высокую скорость работы и хорошее качество классификации на разных датасетах. Bag of Words также можно считать сильным базовым методом, однако TF-IDF является более устойчивым за счет дополнительного взвешивания слов. Методы на основе эмбедингов могут быть улучшены в дальнейшем за счет подбора гиперпараметров, более длительного обучения, использования более крупных корпусов и применения более сложных спо-

способов построения вектора документа, например взвешенного усреднения эмбедингов или нейросетевых архитектур.

Список литературы

- [1] Salton G., Buckley C. *Term-weighting approaches in automatic text retrieval*. Information Processing & Management, 1988.
- [2] Mikolov T., Chen K., Corrado G., Dean J. *Efficient Estimation of Word Representations in Vector Space*. arXiv preprint arXiv:1301.3781, 2013.
- [3] Bojanowski P., Grave E., Joulin A., Mikolov T. Enriching Word Vectors with Subword Information. Transactions of the Association for Computational Linguistics, 2017.
- [4] Joulin A., Grave E., Bojanowski P., Mikolov T. *Bag of Tricks for Efficient Text Classification*. Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics, 2017.